

Training Unit 7

影像品質二分類與 Top-100 排名分析

姓名：林慧心 學號：413410020

2026 年 7 月 26 日

摘要

本作業以 500 張山區道路與落石情境影像為資料集，先完成 Good/Bad 二元分類，再進一步以連續品質分數建立影像品質排名。基礎任務比較 VGG16、ResNet18 與 ResNet50，並以驗證集 F1-score 選擇 checkpoint；進階任務則在人工 Top-100 嚴格隔離的條件下，以 SmoothL1Loss 訓練三個品質迴歸模型，建立原始分數、信心修正分數及三模型集成分數。最後使用 Intersection、Overlap、Jaccard 與 AP 比較模型 Top-100 和人工 Top-100，並分析人機一致與差異案例。

目錄

1	方法與模型架構	3
1.1	資料集與實驗流程	3
1.2	模型架構	3
1.3	超參數與重現性設定	4
2	任務定義與人工標註準則	4
2.1	Good/Bad 二元標籤	4
2.2	進階人工 Top-100 規則	5
2.3	品質訓練目標	6
3	基礎任務結果與分析	6
3.1	訓練曲線與超參數比較	6
3.2	完整候選池分類分布	8
3.3	最終人工參考集結果	9

3.4 正確與錯誤預測案例	11
4 進階任務：品質分數與人工 Top-100 比較	12
4.1 品質分數定義	12
4.2 進階訓練表現	13
4.3 Top-100 與人工參考集比較	15
4.4 AP 與 mAP 的命名	16
4.5 三類質化案例	16
4.5.1 人工與模型共同選中	16
4.5.2 人工選中但模型漏掉	17
4.5.3 模型選中但人工未選	18
5 結論與討論	18
6 AI 工具使用說明	19
7 實驗連結與重現資訊	19
A 完整結果檔案索引	19

1 方法與模型架構

1.1 資料集與實驗流程

資料集共有 500 張影像，影像路徑固定於 data/raw/。基礎任務與進階任務採用不同的資料協定，避免把最終人工參考集合用於模型選擇。

表 1: 基礎與進階任務資料切分

任務	候選池	訓練集	驗證集	最終人工參考集
基礎二分類	500	300	100	100 (Good 50 / Bad 50)
進階品質排名	500	300	100	人工最佳 Top-100

兩套資料切分皆無 train、validation 與 reference 交集。基礎參考集僅用於最終二分類比較；進階人工 Top-100 僅用於模型與排名公式全部固定後的最終比較。

1.2 模型架構

本實驗使用 ImageNet 預訓練的 VGG16、ResNet18 與 ResNet50。基礎任務將最後分類層改為兩個輸出節點，分別代表 Bad 與 Good；進階任務則將最後一層改為單一、不設上下界的連續迴歸輸出。

表 2: 模型輸出形式

任務	輸出層	訓練目標與損失函數
基礎二分類	2 維 logits (Bad / Good)	Good/Bad 標籤，Cross-Entropy Loss
進階品質排名	1 維無界連續分數	人工 1-10 品質分數，SmoothL1Loss

1.3 超參數與重現性設定

表 3: 正式基礎二分類實驗設定

模型	Learning rate	Batch	Epochs	Input	Optimizer	Pretrained
VGG16	0.0001	32	30	224	AdamW	Yes
ResNet18	0.0001	32	30	224	AdamW	Yes
ResNet18	0.001	32	30	224	AdamW	Yes
ResNet50	0.0001	32	30	224	AdamW	Yes

表 4: 正式進階品質迴歸實驗設定

模型	LR	Batch	Epochs	Input	Optimizer	Loss	Pretrained
VGG16	0.0001	32	30	224	AdamW	SmoothL1	Yes
ResNet18	0.0001	32	30	224	AdamW	SmoothL1	Yes
ResNet50	0.0001	32	30	224	AdamW	SmoothL1	Yes

所有正式重跑均使用 random seed 20260725，並固定 Python、NumPy、PyTorch 與 DataLoader generator 的隨機狀態；cuDNN 設為 deterministic。最終重跑環境為 Python 3.12.3、PyTorch 2.6，GPU 為 NVIDIA Tesla V100-SXM2-32GB。

2 任務定義與人工標註準則

2.1 Good/Bad 二元標籤

每張影像先由人工給予 1–10 分品質分數，並使用下列固定門檻產生二元標籤：

$$y = \begin{cases} 0 \text{ (Bad)}, & 1 \leq s \leq 7, \\ 1 \text{ (Good)}, & 8 \leq s \leq 10. \end{cases} \quad (1)$$

人工評分考量道路可見程度、障礙物可辨識程度、影像清晰度、遮擋程度與場景真實性。基礎參考集包含 50 張 Good 與 50 張 Bad，並涵蓋容易判斷及邊界案例。

表 5: 人工影像品質評分規準

評分項目	0 分	1 分	2 分
道路可見程度	道路幾乎不可見	道路僅部分可見	道路清楚可見
障礙物可辨識程度	障礙物無法判讀	障礙物僅部分可判讀	障礙物輪廓與位置清楚可辨識
影像清晰度	嚴重模糊或失焦	輕微模糊，但主要內容仍可判斷	影像清楚
遮擋程度	道路或障礙物等重要區域嚴重遮擋	重要區域部分遮擋	重要區域幾乎沒有遮擋
場景真實性	明顯不合理，例如石塊浮空、路面融合或物理結構崩壞	略顯不自然，例如帶有生成影像的油畫感或局部破綻，但不影響整體判斷	光影、幾何及物件關係自然，符合真實山區道路情境

五個項目各給予 0–2 分後加總，理論總分範圍為 0–10 分；本資料集實際記錄採 1–10 分，沒有使用總分 0。此規準在標註 500 張影像前固定，所有影像皆採相同方式評估。二元任務再依式 (1) 將 1–7 分標為 Bad、8–10 分標為 Good；進階任務則保留原始連續總分作為品質監督訊號。

2.2 進階人工 Top-100 規則

在查看任何進階模型分數、Top-100、Overlap、Jaccard 或 AP 前，先固定完整 500 張候選池，並依下列規則選出人工最佳 100 張：

1. 道路範圍與關鍵道路資訊清楚。
2. 障礙物輪廓、位置與道路關係可可靠判讀。
3. 無明顯失焦、嚴重模糊或壓縮失真。
4. 重要道路與障礙物區域沒有嚴重遮擋。
5. 光影、幾何與物件關係自然，符合真實山區道路情境。

人工集合採「優先選 10 分，再由 9 分補足」的方式建立，最後包含 52 張 10 分影像與 48 張 9 分影像，選擇時盡量依系列分散。人工 Top-100 的成員及排名在查看模型結果前鎖定，後續未因模型結果而更換。

2.3 品質訓練目標

進階模型只使用人工 Top-100 以外的 400 張影像。品質目標為原始人工 1-10 分；由於高分影像已進入人工 Top-100，實際進階訓練目標範圍為 4-9。模型輸出為無界實數，且分數越高代表模型判定品質越好。400 張影像再依品質分數分層切成 300 張訓練與 100 張驗證。

3 基礎任務結果與分析

3.1 訓練曲線與超參數比較




圖 1: 基礎任務三模型的 training/validation loss 曲線




圖 2: 基礎任務三模型的 training/validation accuracy 曲線




圖 3: ResNet18 兩組 learning rate 的 validation F1 比較

表 6: 正式基礎實驗的最佳 validation F1

模型	Learning rate	Best epoch	Best validation F1	W&B run ID
ResNet18	0.0001	2	0.7869	z9fy0ef9
ResNet18	0.001	17	0.8112	6d6u2ku1
VGG16	0.0001	4	0.8308	sgxudag7
ResNet50	0.0001	5	0.8652	af8dkst0

NAME 4 of 10 listed	MODEL_NAME	BATCH_SIZE	OPTIMIZER	EPOCHS	INPUT_SIZE	PRETRAINED	RANDOM_SE	LEARNING_F	BEST_EPOCH	BEST_VAL_F
resnet50...ducible	resnet50	32	AdamW	30	224	true	20260725	0.0001	5	0.86525
vgg16...ducible	vgg16	32	AdamW	30	224	true	20260725	0.0001	4	0.83077
resnet18...parison	resnet18	32	AdamW	30	224	true	20260725	0.001	17	0.81119
resnet18...elected	resnet18	32	AdamW	30	224	true	20260725	0.0001	2	0.78689

圖 4: 基礎任務正式 W&B runs 的設定與結果總表

ResNet18 的 learning rate 由 0.0001 提高至 0.001 後，最佳 validation F1 由 0.7869 提升至 0.8112，因此後續參考集推論採用 LR=0.001 的 checkpoint。三種架構中，ResNet50 的最佳 validation F1 最高。所有選擇皆只依 validation 結果完成，沒有使用最終參考集。

3.2 完整候選池分類分布

三個已固定 checkpoint 另以與 validation 相同的確定性前處理，分別對完整 500 張候選影像執行分類，共產生 1500 筆唯一的模型／影像預測。所有預測均無缺失值、重複值、

NaN 或 Inf，且每筆 Good / Bad 機率和在浮點誤差範圍內等於 1。

表 7: 三模型對完整 500 張候選池的預測標籤分布

模型	Predicted Bad	Predicted Good	Total	Bad ratio	Good ratio
VGG16	147	353	500	0.294	0.706
ResNet18	82	418	500	0.164	0.836
ResNet50	117	383	500	0.234	0.766

表 7 顯示三個模型皆將多數候選影像預測為 Good，其中 ResNet18 的 Good 比例最高（83.6%），ResNet50 次之（76.6%），VGG16 最低（70.6%）。此相對順序與三模型在人工參考集上的 false-positive 傾向一致，支持模型整體偏向 Good 的觀察。由於完整候選池包含訓練集與驗證集影像，本表只用來描述固定模型的整體分類分布與模型差異，不將其解讀為獨立測試集的泛化 Accuracy；正式最終比較仍以第 3.3 節的嚴格隔離人工參考集為準。

3.3 最終人工參考集結果

表 8: 三模型在 100 張人工參考集上的二分類結果

模型	Acc.	Prec.	Recall	F1	TN	FP	FN	TP
VGG16	0.77	0.6849	1.00	0.8130	27	23	0	50
ResNet18	0.56	0.5333	0.96	0.6857	8	42	2	48
ResNet50	0.64	0.5814	1.00	0.7353	14	36	0	50




圖 5: 三模型在人工參考集上的混淆矩陣

雖然 ResNet50 在 validation F1 最佳，但 VGG16 在嚴格隔離的人工參考集上取得最高 F1 (0.8130)。這個差異可能反映資料量有限、validation 與 reference 的場景分布差異，以及模型對 Good 類別的偏好。三模型皆出現較多 false positive，尤其 ResNet18 將 42 張人工 Bad 判為 Good，顯示模型容易把清晰度或高對比誤認為整體品質。

3.4 正確與錯誤預測案例



p1_seed12

人工 Bad、VGG16 判為 Bad；
道路資訊不足，模型正確辨識
為低品質。



p6_img19

人工 Bad、VGG16 判為 Bad；
畫面以落石近景為主，缺少完
整道路脈絡。




p0_img21

人工 Good、VGG16 判為
Good；道路、落石能夠辨識、
畫面清晰。



p2_img19

人工 Good、VGG16 判為
Good；障礙物清晰、道路略為
可辨。



p2_seed0

人工 Good、VGG16 判為
Good；曝光自然、道路輪廓完
整且清晰。

圖 6: VGG16 正確預測案例



p7_img12

人工 Bad、模型判 Good；模型可能偏重道路可見與畫面清晰，低估障礙物影響。



p3_img12

人工 Bad、模型判 Good；缺少完整道路任務資訊、障礙物微不易辨識。



p9_img5

人工 Bad、模型判 Good；模型可能偏重障礙物可見與畫面清晰，低估道路不可見影響。



p0_img1

人工 Bad、模型判 Good；道路可見，但細碎落石與路側損壞降低實用性。



p2_img12

人工 Bad、模型判 Good；影像清晰但道路遭遮擋且後段障礙物微不易辨識。

圖 7: VGG16 錯誤預測案例

五個錯誤案例皆為人工 Bad、模型預測 Good，支持前述模型偏向 Good 的觀察。模型較容易學到亮度、清晰度或局部道路紋理，但未充分理解道路完整性、遮擋程度及場景真實性。

4 進階任務：品質分數與人工 Top-100 比較

4.1 品質分數定義

令模型對影像 x_i 的原始品質分數為 s_i 。原始分數使用與 validation 相同的確定性前處理。信心修正分數使用五次固定 random seed 的 test-time augmentation (TTA)，定義為：

$$s_i^{\text{adj}} = \mu_i^{\text{TTA}} - 0.5 \sigma_i^{\text{TTA}}, \quad (2)$$

其中 μ_i^{TTA} 與 σ_i^{TTA} 分別為五次 TTA 預測的平均與標準差。係數 0.5 在查看人工比較結果前固定。

為避免不同模型的輸出尺度支配集成結果，先將各模型分數轉為 z-score，再取三模型平均：

$$s_i^{\text{ens}} = \frac{1}{3} \sum_{m \in \{\text{VGG16}, \text{R18}, \text{R50}\}} \frac{s_{i,m} - \mu_m}{\sigma_m}. \quad (3)$$

4.2 進階訓練表現




圖 8: 三個品質迴歸模型的 training/validation loss 曲線




圖 9: 三個品質迴歸模型的 validation MAE、RMSE 與 Spearman correlation

表 9: 進階正式訓練的最佳 validation 結果

模型	Best epoch	MAE	RMSE	Spearman	W&B run ID
VGG16	30	0.7169	0.9043	0.5830	rwu768x7
ResNet18	13	0.9856	1.4851	0.3569	g409y4vj
ResNet50	15	1.0081	1.2864	0.4796	ijwx6i2k

NAME	LEARNING_F	BATCH_SIZE	OPTIMIZER	EPOCHS	INPUT_SIZE	PRETRAINED	RANDOM_SE	LOSS	OUTPUT_FO	QUALITY_TA	OBSERVED_	TARGET_SOI	BEST_EPOCH	BEST_VAL_P	BEST_VAL
resnet50_bs32	0.0001	32	AdamW	30	224	true	20260725	SmoothL1Loss	continuous_reg	1-10 human qua	4-9	Manual 1-10 qua	15	1.00813	0.47957
vgg16_bs32	0.0001	32	AdamW	30	224	true	20260725	SmoothL1Loss	continuous_reg	1-10 human qua	4-9	Manual 1-10 qua	30	0.71687	0.583
resnet18_bs32	0.0001	32	AdamW	30	224	true	20260725	SmoothL1Loss	continuous_reg	1-10 human qua	4-9	Manual 1-10 qua	13	0.98565	0.35694

圖 10: 進階任務三個正式 W&B runs 的設定與最佳驗證結果

VGG16 在 checkpoint-selected epoch 上同時取得最低 validation MAE (0.7169)、最低 RMSE (0.9043) 與最高 Spearman correlation (0.5830)，表示它最能貼近非人工 Top-100 驗證集的 1-10 分品質目標。然而，最終人工 Top-100 比較中最高 AP 來自 ResNet18 adjusted，而非 VGG16。這個差異並不矛盾：validation 指標衡量 400 張非參考影像切分中的分數誤差與相關性；最終 AP 則衡量鎖定人工 Top-100 在完整 500 張候選池排序中的位置。兩者的評估目標與資料角色不同，因此 validation regression 表現最佳不保證最終 Top-100 AP 最高。

4.3 Top-100 與人工參考集比較

Overlap 與 Jaccard 衡量兩個 Top-100 集合的一致程度，AP 則衡量模型在完整候選池上的整體排序品質；三者都是集合或排序層級的評估指標，不能視為任何單張圖片的品質分數。單張圖片可具有模型輸出的 raw 或 adjusted 品質分數，以及是否屬於人工 Top-100 的相關性標記，但不具有個別的 Overlap、Jaccard 或 AP。

模型 Top-100 與人工 Top-100 的交集數量記為 $|A \cap B|$ 。由於兩組皆為 100 張：

$$\text{Overlap} = \frac{|A \cap B|}{100}, \quad (4)$$

$$\text{Jaccard} = \frac{|A \cap B|}{|A \cup B|}. \quad (5)$$

表 10: 各模型與排序方式相對人工 Top-100 的結果

Ranking method	Intersection	Overlap	Jaccard	AP
VGG16 raw	26	0.26	0.1494	0.2890
VGG16 adjusted	30	0.30	0.1765	0.2967
ResNet18 raw	34	0.34	0.2048	0.3015
ResNet18 adjusted	34	0.34	0.2048	0.3102
ResNet50 raw	27	0.27	0.1561	0.2666
ResNet50 adjusted	27	0.27	0.1561	0.2740
Ensemble raw	33	0.33	0.1976	0.2861
Ensemble adjusted	33	0.33	0.1976	0.2937

	ranking_method	intersection	overlap	jaccard	ap
1	vgg16_raw_score	26	0.26	0.1494	0.289
2	vgg16_adjusted_score	30	0.3	0.1765	0.2967
3	resnet18_raw_score	34	0.34	0.2048	0.3015
4	resnet18_adjusted_score	34	0.34	0.2048	0.3102
5	resnet50_raw_score	27	0.27	0.1561	0.2666
6	resnet50_adjusted_score	27	0.27	0.1561	0.274
7	ensemble_raw_score	33	0.33	0.1976	0.2861
8	ensemble_adjusted_score	33	0.33	0.1976	0.2937

圖 11: W&B 最終 ranking evaluation 的 Intersection、Overlap、Jaccard 與 AP

三個 raw 模型中，ResNet18 與人工 Top-100 的交集最多，為 34 張。信心修正後，VGG16 的 Intersection 由 26 提升至 30，Overlap 與 Jaccard 也同步改善；ResNet18、ResNet50 與 ensemble 的 Top-100 集合數量指標沒有改變，但四種 adjusted 方法的 AP 皆高於各自 raw 版

本。這表示不確定性懲罰主要改善完整 500 張候選池的排序次序，不一定改變 Top-100 邊界內的成員。

最佳 AP 為 ResNet18 adjusted 的 0.3102。三模型 ensemble 沒有超越最佳單一模型，可能是較弱模型的排序誤差在平均後稀釋了 ResNet18 的有效訊號。完整 Top-100 表已附於 [tables/top100/](#)，主文以表 10 呈現摘要結果。

4.4 AP 與 mAP 的命名

AP 使用完整 500 張候選影像的連續品質分數計算，將人工 Top-100 視為相關樣本，其餘 400 張視為非相關樣本。若只把模型 Top-100 轉成 0/1，會丟失 Top-100 內部及邊界外的排序資訊，因此不能用來正確計算 AP。本實驗只有一組人工參考集合，只有一個 AP 值，故報告使用 AP，而非對多個 query 或多個 AP 取平均的 mAP。


4.5 三類質化案例

4.5.1 人工與模型共同選中




p2_seed25

道路清晰、環境自然，模型和人工皆判定具高品質。



p4_img0

大型障礙物、道路位置與尺度關係清楚。




p0_img9

道路清晰可辨，影像資訊完整。



p3_img22

即使有霧與濕滑條件，道路和大型落石仍可辨識。



p8_img27

道路、散落岩石與環境光線自然，任務資訊充分。

圖 12: 人工與 ResNet18 adjusted 共同選中的案例

共同選中的影像通常同時具備清楚道路邊界、可辨識障礙物、合理光影與足夠場景脈絡，表示模型確實學到部分符合人工規則的品質特徵。

4.5.2 人工選中但模型漏掉



p0_img12

人工重視道路與路側落石資訊，但模型排名僅第 317。




p0_seed1

道路可見但場景構圖特殊，可能偏離模型常見分布。




p1_img10

夜間強光屬少見場景，模型可能因亮度分布不同而低估。



p2_img25

近距離落石與濕滑道路清楚，但構圖與一般全景不同。



p2_seed10

道路完整且自然，模型可能因障礙物訊號較弱而低估。

圖 13: 人工選中但 ResNet18 adjusted 漏掉的案例

這些案例顯示模型可能忽略少見光線、特殊構圖、近距離視角，以及「道路本身完整自然」這類不依賴明顯落石紋理的高品質特徵。

4.5.3 模型選中但人工未選




p0_img29

畫面清楚，但道路遭遮擋、後半路段略為扭曲不自然，人工未列入最佳集合。



p3_img8

岩石清晰、局部對比強，但道路幾乎不可辨識且畫面略微模糊。




p9_img11

岩石紋理明顯，但缺少完整道路資訊、場景不真實，人工評為 Bad。



p5_seed29

高亮度與強對比突出，但山體光線和場景真實性不足。



p9_img15

障礙物可辨，卻幾乎沒有道路任務資訊。

圖 14: ResNet18 adjusted 選中但人工未選的案例

模型限定案例顯示 ResNet18 可能偏好清晰岩石紋理、高亮度、高對比或具視覺吸引力的背景，而沒有充分確認道路是否存在、場景是否自然以及影像是否真正適用於道路障礙物判讀。

5 結論與討論

基礎任務中，ResNet50 的 validation F1 最高，但 VGG16 在最終人工參考集上表現最佳，顯示小型資料集的 validation 排名未必能完全代表新場景。三模型皆偏向將影像判為 Good，後續可透過增加困難 Bad 案例、使用 class-aware sampling 或更強的道路區域特徵來改善 false positive。

進階任務中，ResNet18 adjusted 取得最高 AP 0.3102，且其 Top-100 和人工集合交集為 34 張。信心修正對完整排序有一致的 AP 改善，但 ensemble 未優於最佳單一模型，表示簡單平均無法保證互補。質化案例進一步顯示，模型已學到清晰度與障礙物紋理，但對道路

完整性、真實性與少見場景的理解仍有限。

本實驗的主要限制包括影像總量僅 500 張、人工分數具有主觀性、進階訓練分數範圍因隔離 Top-100 而縮小至 4-9，以及人工參考集合只有一組。未來可增加多位標註者、計算標註一致性、擴充少見場景，並嘗試 ordinal regression、pairwise ranking loss 或經 validation 預先固定的加權 ensemble。

6 AI 工具使用說明

本作業使用生成式 AI / Codex 協助：

- 整理作業需求、資料依賴與執行順序。
- 檢查資料切分是否重疊，產生可重現的資料處理與評估程式。
- 協助檢查推論程式中的 BatchNorm / TTA 問題及重現性設定。
- 整理 W&B config、結果表、案例候選與 LaTeX 報告格式。

影像品質分數、Good/Bad 門檻、人工 Top-100 成員及最終案例取捨均由使用者確認。AI 不參與模型最終測試標籤的自動決策，也沒有使用人工參考結果反覆調整模型、checkpoint 或排名係數。

7 實驗連結與重現資訊

- GitHub：<https://github.com/Klorious/Summer-Training-Week7>
- 基礎任務 W&B project：[training-Unit7-Binary](#)
- 基礎最終評估 run：[bkfn0726](#)
- 進階任務 W&B project：[training-Unit7-Ranking](#)
- 進階最終評估 run：[rkfn0726](#)

A 完整結果檔案索引

檔案	說明
binary_reference_metrics.csv	三模型最終 Accuracy、Precision、Recall、F1 與 confusion matrix 計數。
reference_results.csv	三模型對 100 張參考集的完整 300 筆預測。
binary_candidate_pool_predictions.csv	三模型對完整 500 張候選池的 1500 筆預測。
binary_candidate_pool_distribution.csv	三模型在完整候選池上的 Good / Bad 數量與比例。
all_model_scores.csv	500 張候選影像的三模型 raw / adjusted 與 ensemble 分數。
ranking_metrics.csv	8 種排序方式的 Intersection、Overlap、Jaccard 與 AP。
tables/top100/*.csv	各模型與各排序方法的完整 Top-100 表。